

Examen Lab

Carlos Santiago Martinez Torres

2025-05-26

Contents

1 Creacion de proyecto	1
1.1 Configuracion inicial	1
1.2 Carpetas de interes	1
2 Importacion	2
3 Consultas eventos	3
4 Mas conexiones	4
5 Mejor dia para parar AV	5
6 Contexto DataCamp	6
7 Direccion IP	8
8 Logs por usuario	9

1 Creacion de proyecto

1.1 Configuracion inicial

Limpiamos el entorno para no tener conflicto con ficheros o archivos anteriores.

Instalamos las librerias necesarias para este proyecto.

1.2 Carpetas de interes

Creamos las carpetas para almacenar los ficheros a tratar y figuras, en caso de ser necesarias.

2 Importacion

Importamos el fichero que esta almacenado en la carpeta data.

```
f <- paste0(datos, 'logs_2024_25_TD.csv')
```

```
# Codificacion mas probable
guess_encoding(file = f) # UTF-8
```

```
## # A tibble: 3 x 2
##   encoding confidence
##   <chr>         <dbl>
## 1 UTF-8             1
## 2 ISO-8859-1       0.55
## 3 ISO-8859-2       0.29
```

```
# Importacion
df <- read.csv(file = f, header = TRUE)

# Renombrar
colnames(df) <- c('Hora', 'Contexto', 'Componente', 'NomEv', 'Descripcion', 'Origen', 'IP', 'User')
colnames(df)
```

```
## [1] "Hora"          "Contexto"      "Componente"    "NomEv"         "Descripcion"
## [6] "Origen"        "IP"            "User"
```

```
# Cambio de formato de Hora
df <- df %>%
  mutate(Hora = dmy_hms(Hora))

head(df, 5)
```

```
##           Hora                               Contexto
## 1 2025-05-06 22:50:31 Curso: 2024-25 Tractament de les dades Gr.A-T (36423)
## 2 2025-05-06 22:50:29 Curso: 2024-25 Tractament de les dades Gr.A-T (36423)
## 3 2025-05-06 22:44:12 Curso: 2024-25 Tractament de les dades Gr.A-T (36423)
## 4 2025-05-06 22:43:49           Archivo: Examen escrito 2022 1ª convocatoria
## 5 2025-05-06 22:41:52                               Cuestionario: Cuestionario Tema 5
##   Componente                               NomEv
## 1 Sistema Lista de usuarios vista
## 2 Sistema Lista de usuarios vista
## 3 Sistema                               Curso visto
## 4 Recurso Módulo de curso visto
## 5 Cuestionario Módulo de curso visto
##
## 1 The user with id &#039;22872&#039;; viewed the list of users in the course with id &#039;36423&#039;
## 2 The user with id &#039;22872&#039;; viewed the list of users in the course with id &#039;36423&#039;
## 3 The user with id &#039;22872&#039;; viewed the course with id &#039;36423&#039;
## 4 The user with id &#039;22872&#039;; viewed the &#039;resource&#039;; activity with course module id &#039;36423&#039;
## 5 The user with id &#039;305739&#039;; viewed the &#039;quiz&#039;; activity with course module id &#039;36423&#039;
##   Origen      IP      User
## 1 web 62.43.76.160 143ff85a
```

```
## 2    web 62.43.76.160 143ff85a
## 3    web 62.43.76.160 143ff85a
## 4    web 62.43.76.160 143ff85a
## 5    web 90.69.79.109 612cb0a9
```

```
# Comprobamos
str(df)
```

```
## 'data.frame':    66710 obs. of  8 variables:
## $ Hora          : POSIXct, format: "2025-05-06 22:50:31" "2025-05-06 22:50:29" ...
## $ Contexto      : chr  "Curso: 2024-25 Tractament de les dades Gr.A-T (36423)" "Curso: 2024-25 Tractam
## $ Componente    : chr  "Sistema" "Sistema" "Sistema" "Recurso" ...
## $ NomEv         : chr  "Lista de usuarios vista" "Lista de usuarios vista" "Curso visto" "Módulo de cu
## $ Descripcion   : chr  "The user with id &#039;22872&#039; viewed the list of users in the course with
## $ Origen        : chr  "web" "web" "web" "web" ...
## $ IP            : chr  "62.43.76.160" "62.43.76.160" "62.43.76.160" "62.43.76.160" ...
## $ User          : chr  "143ff85a" "143ff85a" "143ff85a" "143ff85a" ...
```

3 Consultas eventos

Listado de usuarios distintos registrados.

```
# Usuarios distintos
# df %>%
#   distinct(User)
```

Total de usuarios distintos.

```
# Total usuarios distintos
df %>%
  distinct(User) %>%
  count()
```

```
##      n
## 1  84
```

Usuarios con mas y menos logs.

```
# 5 usuarios con mas logs
df %>%
  group_by(User) %>%
  count() %>%
  arrange(desc(n)) %>%
  head(5)
```

```
## # A tibble: 5 x 2
## # Groups:   User [5]
##   User      n
##   <chr>   <int>
## 1 143ff85a  8258
```

```
## 2 bd80f01c 1606
## 3 6cd957b7 1484
## 4 7c8e8f5c 1296
## 5 d5007f33 1277
```

```
# 5 usuarios con menos logs
df %>%
  group_by(User) %>%
  count() %>%
  arrange(n) %>%
  head(5)
```

```
## # A tibble: 5 x 2
## # Groups:   User [5]
##   User      n
##   <chr>   <int>
## 1 8b6b27a2     1
## 2 c90f5c72     1
## 3 b237792a     2
## 4 b45bab56     3
## 5 f6d97665     3
```


4 Mas conexiones

Actualizamos el df creando las variables con la hora redondeada y con la hora especifica del dia.

```
# Horas y dias
df <- df %>%
  mutate(HoraR = floor_date(Hora, unit = 'hour'),
         HoraDia = hour(HoraR))

df %>%
  ggplot(data = ., mapping = aes(x = HoraDia)) +
  geom_bar() +
  labs(title = 'Conexiones realizadas cada hora')
```

Conexiones realizadas cada hora



Teniendo en cuenta el apartado anterior, tomamos los registros que tengan una hora entre 2 y 4.

```
# Eventos entre 2 y 4
df %>%
  filter(HoraDia > 2 & HoraDia < 4) %>%
  count()
```

```
##      n
## 1  36
```

5 Mejor día para parar AV


```
df %>%
  select(Hora) %>%
  mutate(dia = format(x = as.Date(Hora), format = '%A')) %>%
  count(dia) %>%
  arrange(n)
```

```
##      dia      n
## 1  sábado  1762
## 2  domingo  2640
## 3   lunes  9383
## 4  jueves  9941
```

```
## 5   viernes 12036
## 6   martes 14079
## 7   miércoles 16869
```

El mejor día para parar el AV es el sábado, que es cuando menos conexiones hay.

```
# dias_semana <- c('lunes', 'martes', 'miercoles', 'jueves', 'viernes')
df %>%
  select(Hora) %>%
  mutate(dia = format(x = as.Date(Hora), format = '%A')) %>%
  # count(dia) %>%
  ggplot(data = ., mapping = aes(x = dia)) +
  geom_bar(aes(color = dia)) +
  labs(title = 'Cantidad de logs por dia',
       y = 'Logs',
       x = 'dia')
```



6 Contexto DataCamp

Identificamos la cantidad de cursos distintos que hay de DataCamp para contar cuantos hay por cada uno y graficar para ver si estan solapados o no en cuanto a las fechas.

```
# datacamp <- df[str_detect(string = df$NomEv, pattern = 'Entrega creada'), ]
```

```
# Cursos distintos
```

```
df %>%
```

```
  filter(grepl('DataCamp', Contexto, ignore.case = TRUE) & grepl('Entrega creada', NomEv, ignore.case = TRUE))
  distinct(Contexto)
```

```
##                               Contexto
## 1      Tarea: Tarea Cleaning Data in R(Datacamp)
## 2      Tarea: Tarea Understanding Data Visualization (Datacamp)
## 3      Tarea: Tarea Introduction to Importing Data in R(Datacamp)
## 4      Tarea: Tarea Intermediate R(Datacamp)
## 5      Tarea: Tarea Introduction to R(Datacamp)
```

```
# Alumnos por curso
```

```
df %>%
```


```
  filter(grepl('DataCamp', Contexto, ignore.case = TRUE) & grepl('Entrega creada', NomEv, ignore.case = TRUE))
  count(Contexto)
```

```
##                               Contexto  n
## 1      Tarea: Tarea Cleaning Data in R(Datacamp) 39
## 2      Tarea: Tarea Intermediate R(Datacamp) 62
## 3      Tarea: Tarea Introduction to Importing Data in R(Datacamp) 58
## 4      Tarea: Tarea Introduction to R(Datacamp) 54
## 5      Tarea: Tarea Understanding Data Visualization (Datacamp) 53
```

```
# Cursos solapados
```

```
df %>%
```

```
  filter(grepl('DataCamp', Contexto, ignore.case = TRUE) & grepl('Entrega creada', NomEv, ignore.case = TRUE))
  ggplot(data = ., mapping = aes(x = Hora, y = User, color = Contexto)) +
  geom_point()
```



Contexto

- Tarea: Tarea Cleaning Data in R(Datacamp)
- Tarea: Tarea Intermediate R(Datacamp)
- Tarea: Tarea Introduction to Importing Data in R(Datacamp)
- Tarea: Tarea Introduction to R(Datacamp)
- Tarea: Tarea Understanding Data Visualization (Datacamp)

7 Direccion IP

Identifamos las IP con el formato correcto

```
formatoIP = '([0-9])+{3}\\.[0-9])+{3}\\.[0-9])+{3}\\.[0-9])+{3}'
```

Obtencion del df que contiene el Id correcto

```
df_IP <- df %>%
  filter(grepl(formatoIP, IP, ignore.case = TRUE))
```

Comprobar el numero de conexiones por usuario

```
# Numero de conexiones - Diferentes IPs
df_IP %>%
  distinct(IP) %>%
  count()
```

```
##      n
## 1  61
```



```
# Numero de usuarios diferentes con el formato de IP correcto
df_IP %>%
  distinct(User) %>%
  count()
```

```
##      n
## 1 22
```

```
# Usuarios con mas de 2 IPs
df_IP %>%
  count(User) %>%
  filter(n > 2) %>%
  arrange(n)
```

```
##      User      n
## 1 81a41f57      3
## 2 94aba949      4
## 3 037d15c4      6
## 4 839606fd      6
## 5 7e6acc29      8
## 6 81b71417      9
## 7 143ff85a     13
## 8 0eacace9     26
## 9 bcae61fc     26
## 10 17065899    27
## 11 86bf8043    68
## 12 2f3f0f35    94
## 13 098febb5   173
## 14 bd80f01c   359
## 15 31bb79af   455
```

8 Logs por usuario

```
mean_logs <- df %>%
  count(User) %>%
  summarise(mean(n))
mean_logs
```

```
##      mean(n)
## 1 794.1667
```

```
# Cantidad de logs por usuario
df %>%
  ggplot(data = ., mapping = aes(x = User)) +
  geom_bar() +
  theme(axis.text.x = element_text(angle = 90))
```

