

Practica 3 - Preparación de datos

Carlos Santiago Martinez Torres

2025-05-25

Contents

Configuracion inicial	1
Carpetas de interes	1
Ejercicio 1	1
Carga de fichero	2
Verificamos el fichero	2
Convertimos a tidy	2
Convertimos factor	2
Ejercicio 2	4

Configuracion inicial

Carpetas de interes

```
# Creamos directorio data si no existe, para guardar los ficheros
if (!file.exists('data')) { dir.create('data') }

# Creamos directorio figure si no existe, para guardar las figuras
if (!file.exists('figure')) { dir.create('figure') }

# Creamos los accesos a cada carpeta
datos <- 'data/'
figuras <- 'figure/'
```

Ejercicio 1

Convierte el dataset `pew_religion` a formato *tidy* usando `gather`. La columna `income` debe contener una variable de tipo `factor` ordenado, el valor `Don't know/refused` será el nivel más alto.

Carga de fichero

```
f1 <- paste0(datos, 'pew_religion.Rdata')
load(file = f1)
```

Verificamos el fichero

```
str(pew_religion)
```

```
## 'data.frame': 18 obs. of 11 variables:
## $ religion : chr "Agnostic" "Atheist" "Buddhist" "Catholic" ...
## $ <$10k : int 27 12 27 418 15 575 1 228 20 19 ...
## $ $10-20k : int 34 27 21 617 14 869 9 244 27 19 ...
## $ $20-30k : int 60 37 30 732 15 1064 7 236 24 25 ...
## $ $30-40k : int 81 52 34 670 11 982 9 238 24 25 ...
## $ $40-50k : int 76 35 33 638 10 881 11 197 21 30 ...
## $ $50-75k : int 137 70 58 1116 35 1486 34 223 30 95 ...
## $ $75-100k : int 122 73 62 949 21 949 47 131 15 69 ...
## $ $100-150k : int 109 59 39 792 17 723 48 81 11 87 ...
## $ >150k : int 84 74 53 633 18 414 54 78 6 151 ...
## $ Don't know/refused: int 96 76 54 1489 116 1529 37 339 37 162 ...
```

Convertimos a tidy

```
# gather(data = pew_religion, key = 'income', value = 'freq', -religion)
pew_religion <- pew_religion %>%
  pivot_longer(data = ., names_to = 'income', values_to = 'freq', cols = -religion)
head(pew_religion)
```

```
## # A tibble: 6 x 3
## religion income freq
## <chr> <chr> <int>
## 1 Agnostic <$10k 27
## 2 Agnostic $10-20k 34
## 3 Agnostic $20-30k 60
## 4 Agnostic $30-40k 81
## 5 Agnostic $40-50k 76
## 6 Agnostic $50-75k 137
```

Convertimos factor

```
# El factor viene determinado por la variable income
# obtenemos los valores unicos de esa variable

# Niveles de la variable 'income', de tipo factor
# Ordered no sirve en el 'vector' que extraemos
```

```
# niveles_religion <- unique(x = pew_religion$income, ordered = TRUE)
niveles_religion <- unique(x = pew_religion$income)
niveles_religion

# Una vez identificamos los niveles, convertimos la variable a tipo factor
# Dado el orden del vector 'niveles_religion', establecemos que ya está ordenado
# Es decir, las posiciones son las que queremos, y en mutate podemos usar ordered
pew_religion <- pew_religion %>%
  mutate(income = factor(income, levels = niveles_religion, , ordered = TRUE))

# Comprobamos que Don't know/refused sea el nivel mas alto
levels(pew_religion$income)[10] > levels(pew_religion$income)[5]
```

```
# OTRO CAMINO MAS EFICIENTE (?)
# Aprovechando el orden en que se obtienen los valores en unique

niveles_religion <- factor(x = unique(pew_religion$income), ordered = TRUE)

# Comprobamos
levels(niveles_religion)
```

```
## [1] "$10-20k"          "$100-150k"         "$20-30k"
## [4] "$30-40k"          "$40-50k"           "$50-75k"
## [7] "$75-100k"         "<$10k"              ">150k"
## [10] "Don't know/refused"
```

```
niveles_religion # Verificamos el valor más alto
```

```
## [1] <$10k          $10-20k          $20-30k          $30-40k
## [5] $40-50k          $50-75k          $75-100k         $100-150k
## [9] >150k           Don't know/refused
## 10 Levels: $10-20k < $100-150k < $20-30k < $30-40k < $40-50k < ... < Don't know/refused
```

```
niveles_religion[10] > niveles_religion[4]
```

```
## [1] TRUE
```

```
# Actualizamos en el dataframe
pew_religion <- pew_religion %>%
  mutate(income = factor(x = income, levels = niveles_religion))
head(pew_religion)
```

```
## # A tibble: 6 x 3
##   religion income   freq
##   <chr>    <fct> <int>
## 1 Agnostic <$10k     27
## 2 Agnostic $10-20k   34
## 3 Agnostic $20-30k   60
## 4 Agnostic $30-40k   81
## 5 Agnostic $40-50k   76
## 6 Agnostic $50-75k  137
```

Ejercicio 2

Obtén la versión *tidy* de este conjunto de datos usando `pivot_longer`.

Consejo: puedes eliminar el prefijo `wk` de las semanas mediante el argumento `names_prefix`. Opcionalmente puedes crear una columna `date` a partir de `date.entered`, sumando las semanas transcurridas desde la fecha de entrada en lista.

```
# conjunto de datos Billboard
```