

Práctica 6. Análisis Exploratorio de Datos.

Tratamiento de Datos, Grado en Ciencia de Datos - UV

Carlos Santiago Martinez Torres

Contents

Introducción y objetivos	1
Lectura e inspección de los datos	2
Ejercicio 1: Lectura de datos	2
Ejercicio 2: Inspección visual	3
Análisis univariante de variables numéricas	3
Ejercicio 3: Estadísticos básicos	3
Ejercicio 4: Distribución de datos	4
Ejercicio 5: Test de normalidad de la distribución de datos	5
Análisis univariante de variables categóricas	6
Ejercicio 6: Análisis de frecuencias en variables categóricas	6
Análisis bivalente de variables numéricas	7
Ejercicio 7: Matrices de covarianza y correlación	7
Ejercicio 8: Representación gráfica de correlación entre variables	8
Análisis bivalente de variables categóricas	9
Ejercicio 9: Dependencia entre variables categóricas	9
Entrega de ejercicios	10

Introducción y objetivos

El objetivo de esta práctica es realizar un análisis exploratorio de datos: explorando el conjunto de datos; obteniendo los estadísticos básicos de las variables numéricas; visualizando las relaciones entre variables; y calculando las relaciones entre variables tanto numéricas como categóricas.

En esta práctica, las etapas que vamos a considerar en el análisis exploratorio de datos son:

1. Lectura e inspección de los datos.
2. Análisis univariante de los datos: variables numéricas y categóricas.
3. Análisis bivalente de los datos: variables numéricas y categóricas.

Lectura e inspección de los datos

Vamos a trabajar con el conjunto de datos “Nos Autoevaluamos” generado por nosotros al rellenar la tabla de datos de la tarea correspondiente.

Este conjunto contiene datos perdidos e inconsistencias que habrá que corregir antes de analizar la distribución de los datos. Para evitar estas inconsistencias, estos datos deberán ser eliminados, corregidos o imputados, tal y como vimos en la práctica anterior.

El conjunto “NosAutoanalizamos_TD2019 - Hoja 1 - Clean.tsv” ya ha sido procesado en parte para poder trabajar en esta práctica. En él tenemos para cada una de las asignaturas (ALG, ANM, FP, DCS y MD) columnas acabadas en `.num`, con las notas en valor numérico, y columnas acabadas en `.cat`, con valores categóricos: AP para aprobada, NP para no presentado y NC para no compensable.

Variable	Comentarios
Identificación	Usuario de correo
Age	Edad en años
Sex	Sexo: ‘Femenino’, ‘Masculino’
Wr.Hnd	Distancia del extremo del índice al extremo del pulgar en centímetros de la mano con la que escribimos
NW.Hnd	Mano con la que escribes: ‘Izquierda’, ‘Derecha’
Fold	Brazo que está arriba cuando cruzas los brazos: ‘Izquierdo’, ‘Derecho’
Pulse	Ritmo cardíaco, en reposo, en latidos por minuto.
Clap	Posición de las manos al aplaudir: ‘Der s Izd’, (Derecha sobre izquierda) ‘Izq s Der’, ‘Ninguna’
Exer	Días a la semana que realizas ejercicio físico: Numérica de 0-7
Smoke	Fumador: ‘Sí’ / ‘No’
Height	Altura expresada en centímetros
ALG	Calificación obtenida en álgebra. Usa ‘NP’ para no presentado y ‘NC’, para no compensable, si procede
ANM	Calificación obtenida en análisis matemático. Usa ‘NP’ para no presentado y ‘NC’, para no compensable, si procede
FP	Calificación obtenida en fundamentos de programación. Usa ‘NP’ para no presentado y ‘NC’, para no compensable, si procede
DCS	Calificación obtenida en Datos Ciencia y Sociedad. Usa ‘NP’ para no presentado y ‘NC’, para no compensable, si procede
MD	Calificación obtenida en Matemática Discreta. Usa ‘NP’ para no presentado y ‘NC’, para no compensable, si procede
HSt	Horas de trabajo diarias relacionadas con los estudios, además de la asistencia a clase
Hwork	Horas de trabajo remunerado semanales (0 indica que no tiene otro trabajo)
Comentarios	Campo de texto libre para incluir comentarios que consideres sobre la asignatura

Ejercicio 1: Lectura de datos

- Lee los datos del fichero con `read_tsv` a una variable llamada `Datos`.
- Convierte las variables categóricas acabadas en `.cat` a tipo `factor`. Puedes hacerlo:
- Usando la función `mutate_at` (junto con `vars`, `ends_with` y `as.factor`).
- Usando `mutate(across())` (junto con `ends_with` y `as.factor`).

```
fichero <- 'data/NosAutoanalizamos_TD2019 - Hoja 1 - Clean.tsv'
Datos <- read_tsv(fichero)

Datos <- Datos %>%
```

```
mutate(across(.cols = ends_with('.cat'),
              .fns = ~ as.factor(.)))
```

Ejercicio 2: Inspección visual

Inspecciona visualmente los valores del conjunto de datos (**View**) y ordena de mayor a menor y de menor a mayor cada variable.

```
# Datos %>%
#   arrange(desc(Age)) %>%
#   View()

# Datos %>%
#   arrange(Wr.Hnd) %>%
#   View()
```

En las variables vistas, *Age* y *Wr.Hnd*, vemos que la edad máxima es 37 y la mínima es 18, y la distancia máxima en centímetros con la mano con que se escribe es de 22 y la mínima de 12.5.

Para ver las demás variables, solo cambiamos el argumento dentro de *arrange()*.

Análisis univariante de variables numéricas

Ejercicio 3: Estadísticos básicos

Empleando la función `summarise(across())` calcula la media, la desviación típica, mediana y el *interquartile range* (IQR) de las variables que acaban en `.num` (notas numéricas).

- Ten en cuenta que no se puede realizar un análisis estadístico con datos faltantes, pero en la mayoría de los casos se puede optar por no considerar dichos valores al realizar los cálculos (`na.rm=TRUE`).
- Reordena los resultados para generar una tabla en la que tengas en cada fila una de las variables y en cada columna los estadísticos calculados.
 1. Primero usa `pivot_longer` para juntar todo en dos columnas, una para los nombres combinados de las variables y sus estadísticos, y otra para los valores.
 2. Luego usa `separate` para separar la columna de nombres en dos, una llamada `asignatura` con el nombre de la variable, y otra llamada `stat` con el nombre del estadístico.
 3. Por último, usa `pivot_wider` para distribuir la columna `stat` en cuatro columnas, cada una con el nombre del estadístico.
 4. Por último, combina las columnas que almacenan media y desviación típica en una columna, tipo texto, `mean±sd`.

Expresa los resultados con 2 decimales.

El resultado final debe ser una tabla como ésta:

asignatura	mean±sd	median	IQR
ALG.num			
ANM.num			

asignatura	mean±sd	median	IQR
etc			

```
# Estadísticos de todas las columnas numéricas:
funs_apply = list("mean"= mean, "sd"=sd, "median"=median, "IQR"=IQR)

est_bsc <- Datos %>%
  # Estadísticos
  summarise(across(.cols = ends_with('.num'),
    .fns = funs_apply,
    na.rm = TRUE)) %>%
  # Juntar en dos columnas
  pivot_longer(cols = everything(),
    names_to = 'asignatura',
    values_to = 'valor') %>%
  # Separar columna de nombres
  separate(asignatura, into = c('asignatura', 'stat'), sep = '_') %>%
  # Usar pivot_wider para distribuir columna
  pivot_wider(names_from = stat, values_from = valor) %>%
  # Combinar columnas
  mutate('mean±sd' = mean+sd) %>%
  select(asignatura, 'mean±sd', median, IQR)

kable(est_bsc)
```

asignatura	mean±sd	median	IQR
ALG.num	7.543146	6.00	4.00
ANM.num	8.557142	6.70	2.50
DCS.num	8.763241	7.40	1.85
FP.num	8.570562	6.90	3.82
MD.num	7.735653	6.05	2.25


Ejercicio 4: Distribución de datos

Representa gráficamente la curva de notas de la asignatura DCS estimando la distribución de datos: histograma (`geom_histogram`) y curva de densidad (`geom_density`).

- Recuerda que para que los dos representaciones ‘casen’ hay que indicarle a `geom_histogram` que use la función `density` para estimar el histograma, es decir: `geom_histogram(aes(y=stat(density)))`.
- Compara el resultado con la media de las notas para esa asignatura. Puedes marcar dicha media en el gráfico con `geom_point` o con `geom_vline()` especificando el parámetro `xintercept`.

```
ggplot(data = Datos, aes(x=DCS.num)) +
  geom_histogram(aes(y = stat(density)),
    binwidth = 0.5,
    col = 'blue',
    fill = 'red',
    alpha = 0.2, # Transparente 100% = 0
    na.rm=TRUE) +
```

```
geom_density(col='green') +
geom_vline(xintercept = mean(Datos$DCS.num, na.rm = TRUE),
          col = 'red',
          linetype = 'dashed',
          linewidth = 1) +
labs(title = 'Notas de DCS',
     x = 'Nota')
```



Ejercicio 5: Test de normalidad de la distribución de datos


Compara la distribución de probabilidad de las notas de la asignatura DCS con la de una Gaussiana empleando la función `qqPlot` (quantile-quantile plot) de la librería `car`, que representa gráficamente los cuantiles de la distribución analizada respecto de los de una distribución normal (Gaussiana).

Si los datos fueran normales (siguieran una distribución Gaussiana), los puntos seguirían la línea azul. Adicional, la curva hacia arriba, indica valores extremos mayores, mientras que la curva hacia abajo, valores extremos menores.

Permite identificar *Outliers* dentro de los datos. Por ejemplo, ha devuelto que los registros 18 y 19, tienen notas muy bajas (4.0), que se pueden considerar como valores atípicos.

```
library(car)

qqPlot(x = Datos$DCS.num)
```



[1] 18 19

Análisis univariante de variables categóricas

Ejercicio 6: Análisis de frecuencias en variables categóricas

Vamos a calcular la frecuencia de cada valor en las variables categóricas de calificaciones con la función `table`.

- Calcula la frecuencia de cada calificación para la asignatura MD.
- Usa también la función `table` para calcular la tabla de contingencia con la frecuencia de cada combinación de las calificaciones de las asignaturas MD y ANM.
- Representa la tabla de contingencia usando `mosaicplot`.

```
Datos %>%
  select(MD.cat) %>%
  table()
```


```
MD.cat
AP NC NP
44  1  3
```

```
Datos %>%
  select(MD.cat, ANM.cat) %>%
  table()
```

```
      ANM.cat
MD.cat AP NC NP
AP  42  1  1
NC   1  0  0
NP   0  0  3
```

```
Datos %>%
  select(MD.cat, ANM.cat) %>%
  table() %>%
  mosaicplot(main = 'Tabla de contingencia de MD y ANM',
             ylab = 'ANM',
             xlab = 'MD')
```

Tabla de contingencia de MD y ANM



Análisis bivalente de variables numéricas

Ejercicio 7: Matrices de covarianza y correlación

- Calcula las matrices de covarianza (no acotada) y correlación (acotada), considerando todas las variables con las notas numéricas, para encontrar relaciones (lineales) entre variables.
- Compara los resultados para el coeficiente de correlación de Pearson (para variables numéricas) y de Spearman (para variables numéricas ordinales).

```
notas_numericas <- Datos %>%
  select(ends_with('.num'))

covarianza <- cov(notas_numericas, use = 'complete.obs')

cor_pearson <- cor(x = notas_numericas, method = 'pearson', use = 'complete.obs')
cor_pearson
```

	ALG.num	ANM.num	DCS.num	FP.num	MD.num
ALG.num	1.0000000	0.4323642	0.1513110	0.3923448	0.6813766
ANM.num	0.4323642	1.0000000	0.4157273	0.4112944	0.5109338
DCS.num	0.1513110	0.4157273	1.0000000	0.3937829	0.4235482
FP.num	0.3923448	0.4112944	0.3937829	1.0000000	0.4961826
MD.num	0.6813766	0.5109338	0.4235482	0.4961826	1.0000000

```
cor_spearman <- cor(x = notas_numericas, method = 'spearman', use = 'complete.obs')
cor_spearman
```

```
      ALG.num  ANM.num  DCS.num  FP.num  MD.num
ALG.num 1.0000000 0.4540727 0.2578422 0.3752636 0.6662916
ANM.num 0.4540727 1.0000000 0.4246750 0.4529746 0.5232172
DCS.num 0.2578422 0.4246750 1.0000000 0.4421483 0.4006197
FP.num  0.3752636 0.4529746 0.4421483 1.0000000 0.5047492
MD.num  0.6662916 0.5232172 0.4006197 0.5047492 1.0000000
```

La correlación de Pearson sirve para cuando la relación entre dos variables es lineal, mientras que la de Spearman es robusta frente a relaciones no lineales en datos ordenados.

Para comprobarlo, vamos a aplicar una función no lineal a una de las variables y a calcular la correlación usando los métodos de Pearson y Spearman. Compruébalo entre las variables `sqrt(ALG.num)` y `MD.num`, comparando con los resultados anteriores.

```
# Correlacion de Pearson
cor(x = Datos$ALG.num, y = Datos$MD.num, method = 'pearson', use = 'complete.obs')
```

```
[1] 0.6868609
```

```
# Correlacion de Pearson con sqrt(ALG.num)
cor(x = sqrt(Datos$ALG.num), y = Datos$MD.num, method = 'pearson', use = 'complete.obs')
```

```
[1] 0.6357667
```

```
# Correlacion de Spearman
cor(x = Datos$ALG.num, y = Datos$MD.num, method = 'spearman', use = 'complete.obs')
```

```
[1] 0.6653964
```

```
# Correlacion de Spearman con sqrt(ALG.num)
cor(x = sqrt(Datos$ALG.num), y = Datos$MD.num, method = 'spearman', use = 'complete.obs')
```

```
[1] 0.6653964
```

Se puede establecer una relación positiva moderada entre las dos variables. Cuando se aplica la función `sqrt`, se ajusta un poco los datos, pero aún así, mantienen la relación.


Ejercicio 8: Representación gráfica de correlación entre variables

Dibuja las matrices de correlación del conjunto de notas numéricas. Podemos usar `pairs` del paquete `base` o bien `ggcorr` y `ggpairs` de la librería `GGally`.

```
library(GGally)

Datos %>%
  select(ends_with('.num')) %>%
  ggpairs(., title = 'Correlación entre variables numéricas')
```

Correlación entre variables numéricas



Análisis bivalente de variables categóricas

Ejercicio 9: Dependencia entre variables categóricas

Vamos a considerar 2 variables categóricas para determinar su relación en términos de dependencia con el test Chi cuadrado de Pearson (χ^2).

- Comprueba la dependencia entre los tipos de calificaciones de ALG y ANM.
- Comprueba si existe dependencia entre la calificación de ALG y la variable Pulse.

Nota: usa la función `chisq.test` con el parámetro `correct=FALSE` y analiza su significancia estadística (si $p < 0,05$ rechazamos la hipótesis nula de independencia y concluimos que existe dependencia entre las variables).

```
# Dado el valor de p, rechazamos la hipotesis. Por tanto, hay dependencia para ALG y ANM.
chisq.test(Datos$ALG.cat, Datos$ANM.cat, correct = FALSE)
```

Pearson's Chi-squared test

```
data: Datos$ALG.cat and Datos$ANM.cat
X-squared = 36.734, df = 4, p-value = 2.043e-07
```

```
# El valor es mayor a 0.05. Por lo tanto, puede haber relacion entre las variables.
chisq.test(Datos$ALG.cat, Datos$Pulse, correct = FALSE)
```

Pearson's Chi-squared test

```
data: Datos$ALG.cat and Datos$Pulse
X-squared = 44.248, df = 44, p-value = 0.4612
```

Entrega de ejercicios

Al finalizar la práctica debes completar el cuestionario de aula virtual. Debes subir a aula virtual el fichero RMarkdown compilado en html o pdf con las soluciones a los ejercicios planteados.