

Practica 7 - Resumen

Carlos Santiago Martinez Torres

2025-05-25

Contents

Configuracion inicial	1
Carpetas de interes	1
Carga de datos	2
Preparacion de los datos	3
Estadisticos por quality	6
Datos anomalos	7
Matriz	12
Representaciones graficas	13

Configuracion inicial

Carpetas de interes

```
# Creamos directorio data si no existe, para guardar los ficheros
if (!file.exists('data')) { dir.create('data') }

# Creamos directorio figure si no existe, para guardar las figuras
if (!file.exists('figure')) { dir.create('figure') }

# Creamos los accesos a cada carpeta
datos <- 'data/'
figuras <- 'figure/'
```

Carga de datos

- a. Carga en un data frame el contenido del fichero de datos licores.csv. Verifica que las columnas tienen el tipo de dato adecuado a su contenido. Muestra las primeras 10 filas.

```
f <- paste0(datos, 'licores.csv')
licores <- read.csv(file = f, header = TRUE, sep = ',')
head(licores)
```

```
##   fixed.acidity volatile.acidity citric.acid residual.sugar chlorides
## 1          7.4           0.70         0.00           1.9       0.076
## 2          7.8           0.88         0.00           2.6       0.098
## 3          7.8           0.76         0.04           2.3       0.092
## 4         11.2           0.28         0.56           1.9       0.075
## 5          7.4           0.70         0.00           1.9       0.076
## 6          7.4           0.66         0.00           1.8       0.075
##   free.sulfur.dioxide total.sulfur.dioxide density    pH sulphates alcohol
## 1                  11                   34 0.9978 3.51      0.56      9.4
## 2                  25                   67 0.9968 3.20      0.68      9.8
## 3                  15                   54 0.9970 3.26      0.65      9.8
## 4                  17                   60 0.9980 3.16      0.58      9.8
## 5                  11                   34 0.9978 3.51      0.56      9.4
## 6                  13                   40 0.9978 3.51      0.56      9.4
##   quality
## 1        5
## 2        5
## 3        5
## 4        6
## 5        5
## 6        5
```

- b. Indica el número de filas, tipo de datos de cada columna y sus estadísticos básicos. ¿Hay valores especiales (NaN, NA, Inf, -Inf) en alguna columna?

```
# Informacion de filas y columnas
glimpse(x = licores)
```

```
## Rows: 1,599
## Columns: 12
## $ fixed.acidity      <dbl> 7.4, 7.8, 7.8, 11.2, 7.4, 7.4, 7.9, 7.3, 7.8, 7.5~
## $ volatile.acidity  <dbl> 0.700, 0.880, 0.760, 0.280, 0.700, 0.660, 0.600, ~
## $ citric.acid       <dbl> 0.00, 0.00, 0.04, 0.56, 0.00, 0.00, 0.06, 0.00, 0~
## $ residual.sugar    <dbl> 1.9, 2.6, 2.3, 1.9, 1.9, 1.8, 1.6, 1.2, 2.0, 6.1,~
## $ chlorides         <dbl> 0.076, 0.098, 0.092, 0.075, 0.076, 0.075, 0.069, ~
## $ free.sulfur.dioxide <dbl> 11, 25, 15, 17, 11, 13, 15, 15, 9, 17, 15, 17, 16~
## $ total.sulfur.dioxide <dbl> 34, 67, 54, 60, 34, 40, 59, 21, 18, 102, 65, 102,~
## $ density           <dbl> 0.9978, 0.9968, 0.9970, 0.9980, 0.9978, 0.9978, 0~
## $ pH               <dbl> 3.51, 3.20, 3.26, 3.16, 3.51, 3.51, 3.30, 3.39, 3~
## $ sulphates         <dbl> 0.56, 0.68, 0.65, 0.58, 0.56, 0.56, 0.46, 0.47, 0~
## $ alcohol           <dbl> 9.4, 9.8, 9.8, 9.8, 9.4, 9.4, 9.4, 10.0, 9.5, 10.~
## $ quality           <int> 5, 5, 5, 6, 5, 5, 5, 7, 7, 5, 5, 5, 5, 5, 5, 7~
```

```
# Estadísticos básicos
summary(licores)
```

```
## fixed.acidity    volatile.acidity    citric.acid    residual.sugar
## Min.      : 4.60    Min.      :0.1200    Min.      :0.000    Min.      : 0.900
## 1st Qu.: 7.10    1st Qu.:0.3900    1st Qu.:0.090    1st Qu.: 1.900
## Median : 7.90    Median :0.5200    Median :0.260    Median : 2.200
## Mean      : 8.32    Mean      :0.5278    Mean      :0.271    Mean      : 2.539
## 3rd Qu.: 9.20    3rd Qu.:0.6400    3rd Qu.:0.420    3rd Qu.: 2.600
## Max.      :15.90    Max.      :1.5800    Max.      :1.000    Max.      :15.500
## chlorides      free.sulfur.dioxide    total.sulfur.dioxide    density
## Min.      :0.01200    Min.      : 1.00      Min.      : 6.00      Min.      :0.9901
## 1st Qu.:0.07000    1st Qu.: 7.00      1st Qu.: 22.00      1st Qu.:0.9956
## Median :0.07900    Median :14.00      Median : 38.00      Median :0.9968
## Mean      :0.08747    Mean      :15.87      Mean      : 46.47      Mean      :0.9967
## 3rd Qu.:0.09000    3rd Qu.:21.00      3rd Qu.: 62.00      3rd Qu.:0.9978
## Max.      :0.61100    Max.      :72.00      Max.      :289.00      Max.      :1.0037
## pH            sulphates            alcohol            quality
## Min.      :2.740    Min.      :0.3300    Min.      : 8.40      Min.      :3.000
## 1st Qu.:3.210    1st Qu.:0.5500    1st Qu.: 9.50      1st Qu.:5.000
## Median :3.310    Median :0.6200    Median :10.20      Median :6.000
## Mean      :3.311    Mean      :0.6581    Mean      :10.42      Mean      :5.636
## 3rd Qu.:3.400    3rd Qu.:0.7300    3rd Qu.:11.10      3rd Qu.:6.000
## Max.      :4.010    Max.      :2.0000    Max.      :14.90      Max.      :8.000
```

```
# Valores especiales. Inf solo a numericos.
# Si se aplica a otros, lanza error.
sum(is.na(licores))
```

```
## [1] 0
```

C. Sustituye en los nombres de las variables el carácter espacio ' ' por el carácter barra baja '_'.

```
colnames(licores) <- str_replace_all(string = colnames(licores), pattern = '[ ]', replacement = '_') #
colnames(licores)
```

```
## [1] "fixed_acidity"      "volatile_acidity"    "citric_acid"
## [4] "residual_sugar"     "chlorides"           "free_sulfur_dioxide"
## [7] "total_sulfur_dioxide" "density"             "pH"
## [10] "sulphates"          "alcohol"             "quality"
```

Preparacion de los datos

- ¿Qué valores distintos contiene la variable quality? Conviértela a factor y asigna el valor de sus niveles a 'Muy malo', 'Malo', 'Regular', 'Aprobado', 'Bueno' y 'Muy bueno', por orden de menor a mayor valoración. ¿Cuántas muestras (filas) corresponden a cada nivel?

```
# Valores distintos de la variable quality
etiqueta <- c('Muy malo', 'Malo', 'Regular', 'Aprobado', 'Bueno', 'Muy bueno')
```

```
# Forma 1
licores %>%
  distinct(quality) %>% # Tener cuidado con distinct y unique
  arrange(quality) %>%
  as.vector()
```

```
## $quality
## [1] 3 4 5 6 7 8
```

```
# Forma 2
sort(unique(licores$quality)) # Vector con valores de quality ordenados
```

```
## [1] 3 4 5 6 7 8
```

```
# Forma 3
q_licor <- factor(x = sort(unique(licores$quality)), ordered = TRUE)
q_licor
```

```
## [1] 3 4 5 6 7 8
## Levels: 3 < 4 < 5 < 6 < 7 < 8
```

```
# Antes de actualizar, verificamos
licores %>%
  count(quality)
```

```
##   quality    n
## 1      3    10
## 2      4    53
## 3      5   681
## 4      6   638
## 5      7   199
## 6      8    18
```

```
# Actualizamos
licores <- licores %>%
  mutate(quality = factor(x = quality, levels = q_licor, labels = etiqueta))
```

```
# Comprobamos
licores %>%
  count(quality)
```

```
##   quality    n
## 1 Muy malo   10
## 2      Malo   53
## 3 Regular  681
## 4 Aprobado  638
## 5      Bueno 199
## 6 Muy bueno  18
```

b. Realiza las siguientes operaciones:

- Crea otra columna llamada `sulfur_dioxide_ratio` que contenga el resultado del cociente entre las columnas `free_sulfur_dioxide` y `total_sulfur_dioxide`.

```
licores <- licores %>%
  mutate(sulfur_dioxide_ratio = free_sulfur_dioxide/total_sulfur_dioxide)
```

- Elimina las dos columnas que has usado para el cálculo. Elimina también la columna `chlorides`.

```
licores <- licores %>%
  select(-free_sulfur_dioxide, -total_sulfur_dioxide, -chlorides)
```

- Elimina las filas con un `citric acid` < 0.05.

```
licores <- licores %>%
  filter(!citric_acid < 0.05)
```

- Ordena las filas de mayor a menor valor de `alcohol`.

```
licores <- licores %>%
  arrange(desc(alcohol))
```

- Redondea todas las variables numéricas a un máximo de 3 decimales.

```
licores <- licores %>%
  mutate(across(.cols = where(is.numeric),
    .fns = ~round(., 3))) # ~, le estoy pasando más de un valor
```

Enlaza TODAS las operaciones con tuberías y guarda el data frame resultante en la variable `datos_proc`.

```
# datos_proc <- licores
```

A partir de ahora debes usar el dataframe `datos_proc` que has obtenido. NOTA: Si no has resuelto el anterior ejercicio, usa el data frame que se proporciona en el fichero `datos_proc.Rdata` incluido en la carpeta `data`, para responder a las siguientes preguntas:

```
# Cargamos el fichero
f2 <- paste0(datos, 'datos_proc.Rdata')
load(f2)
```

```
# Comprobamos que hayamos obtenido los mismos datos
datos_proc <- datos_proc %>%
  arrange(desc(alcohol))
which(!licores == datos_proc)
```

```
## integer(0)
```

Estadísticos por quality

4. Determina, para cada valor de quality, la media, mediana, desviación estándar y rango intercuartílico de los valores de alcohol, redondeando a 2 decimales. Confecciona una tabla como la siguiente. Fíjate que se debe combinar $\text{media} \pm \text{sd}$ en la misma columna. ¿Observas alguna relación entre el nivel de alcohol y la calidad del licor?

```
# Estadísticos de todas las columnas numéricas
```

```
funs_apply = list('mean' = mean, 'median' = median, 'sd' = sd, 'IQR' = IQR)
```

```
# NOTA: Ya está como un conjunto tidy
```

```
datos_proc %>%
```

```
  group_by(quality) %>%
```

```
  summarise(across(.cols = alcohol,
```

```
    .fns = funs_apply)) # Los nombres quedan alcohol_media, alcohol_median...
```

```
## # A tibble: 6 x 5
```

```
##   quality  alcohol_mean alcohol_median alcohol_sd alcohol_IQR
```

```
##   <fct>      <dbl>         <dbl>      <dbl>      <dbl>
```

```
## 1 Muy malo    9.44            9.7        0.730      0.9
```

```
## 2 Malo       10.3            10         0.993      1.4
```

```
## 3 Regular     9.89            9.6        0.750      0.800
```

```
## 4 Aprobado   10.6            10.5       1.03       1.5
```

```
## 5 Bueno     11.4            11.4       0.926      1.30
```

```
## 6 Muy bueno  12.0            11.8       1.16       1.5
```

```
# Corregimos el nombre de las variables
```

```
datos_proc %>%
```

```
  group_by(quality) %>%
```

```
  summarise(across(.cols = alcohol,
```

```
    .fns = funs_apply,
```

```
    .names = '{.fn}')) # Queda media, median...
```

```
## # A tibble: 6 x 5
```

```
##   quality  mean median    sd  IQR
```

```
##   <fct>    <dbl> <dbl> <dbl> <dbl>
```

```
## 1 Muy malo    9.44    9.7 0.730 0.9
```

```
## 2 Malo       10.3    10  0.993 1.4
```

```
## 3 Regular     9.89    9.6 0.750 0.800
```

```
## 4 Aprobado   10.6    10.5 1.03  1.5
```

```
## 5 Bueno     11.4    11.4 0.926 1.30
```

```
## 6 Muy bueno  12.0    11.8 1.16  1.5
```

```
# Continuamos calculando
```

```
val_alcohol <- datos_proc %>%
```

```
  group_by(quality) %>%
```

```
  summarise(across(.cols = alcohol,
```

```
    .fns = funs_apply,
```

```
    .names = '{.fn}')) %>%
```

```
  mutate('mean+sd' = mean + sd) %>%
```

```
  mutate(across(.cols = where(is.numeric),
```

```
    .fns = ~round(., 2)))
```

```
val_alcohol
```

```
## # A tibble: 6 x 6
##   quality    mean median    sd   IQR 'mean+sd'
##   <fct>      <dbl> <dbl> <dbl> <dbl>   <dbl>
## 1 Muy malo    9.44    9.7  0.73  0.9    10.2
## 2 Malo       10.3    10  0.99  1.4    11.3
## 3 Regular    9.89    9.6  0.75  0.8    10.6
## 4 Aprobado   10.6    10.5 1.03  1.5    11.6
## 5 Bueno     11.4    11.4 0.93  1.3    12.3
## 6 Muy bueno  12.0    11.8 1.16  1.5    13.1
```

Datos anómalos

- Determina si hay algún dato anómalo en las variables numéricas usando las reglas Hampel y Boxplot. Para cada variable añadirás 2 columnas adicionales. Una al aplicar la regla de Hampel y otra al aplicar la regla del Boxplot que indicará si dicho valor es un outlier (TRUE) o no (FALSE).

Suma el número de casos para cada combinación de regla y variable y guarda los resultados como una fila en un data frame outliers.

```
# Definimos las funciones que necesitamos

# Funcion mad() de r

# Funcion que recibe una columna y evalua la desviacion absoluta de la mediana 'median absolute deviat
# madm <- function(v) {
#   mediana <- median(v, na.rm=TRUE) # Cada vez que 'opera el vector', considera los na.
#   valor <- 1.4826 * median(abs(v - mediana), na.rm=TRUE)
#   return(valor)
# }

# Funcion para Identificador Hampel
reglahampel <- function(v) {
  mediana <- median(v, na.rm = TRUE)
  madm <- mad(v)
  return((v < (mediana - (3 * madm)) | (v > (mediana + (3 * madm)))))
}

# Funcion Regla boxplot
reglaboxplot <- function(v){
  xi <- quantile(v, probs = 0.25, na.rm=TRUE)
  xs <- quantile(v, probs = 0.75, na.rm=TRUE)
  iqr <- xs - xi
  return((v < (xi - (1.5 * iqr))) | (v > (xs + (1.5 * iqr))))
}

# Identificacion de outliers
outliers <- datos_proc %>%
  mutate(across(.cols = where(is.numeric),
    .fns = list(reglahampel = reglahampel,
      reglaboxplot = reglaboxplot))) %>%
  summarise(across(.cols = where(is.logical),
```

```

    .fns = ~sum(., na.rm = TRUE)))
outliers

```

```

## # A tibble: 1 x 18
##   fixed_acidity_reglahampel fixed_acidity_reglaboxplot volatile_acidity_reglah-1
##             <int>             <int>             <int>
## 1             34             20             12
## # i abbreviated name: 1: volatile_acidity_reglahampel
## # i 15 more variables: volatile_acidity_reglaboxplot <int>,
## #   citric_acid_reglahampel <int>, citric_acid_reglaboxplot <int>,
## #   residual_sugar_reglahampel <int>, residual_sugar_reglaboxplot <int>,
## #   density_reglahampel <int>, density_reglaboxplot <int>,
## #   pH_reglahampel <int>, pH_reglaboxplot <int>, sulphates_reglahampel <int>,
## #   sulphates_reglaboxplot <int>, alcohol_reglahampel <int>, ...

```

- b. Representa mediante un diagrama de barras la cantidad de outliers detectada para cada variable y en diferente color para cada regla. Coloca las barras unas al lado de las otras.

```

# Convertimos a conjunto tidy
outliers %>%
  pivot_longer(data = ., names_to = 'Variable',
               values_to = 'Valor',
               cols = everything())

```

```

## # A tibble: 18 x 2
##   Variable      Valor
##   <chr>      <int>
## 1 fixed_acidity_reglahampel      34
## 2 fixed_acidity_reglaboxplot     20
## 3 volatile_acidity_reglahampel     12
## 4 volatile_acidity_reglaboxplot     23
## 5 citric_acid_reglahampel         1
## 6 citric_acid_reglaboxplot         1
## 7 residual_sugar_reglahampel    147
## 8 residual_sugar_reglaboxplot   138
## 9 density_reglahampel           34
## 10 density_reglaboxplot          34
## 11 pH_reglahampel                11
## 12 pH_reglaboxplot               19
## 13 sulphates_reglahampel         51
## 14 sulphates_reglaboxplot        51
## 15 alcohol_reglahampel           11
## 16 alcohol_reglaboxplot           7
## 17 sulfur_dioxide_ratio_reglahampel  0
## 18 sulfur_dioxide_ratio_reglaboxplot  5

```

```

# Separar la regla que detecto outlier
outliers <- outliers %>%
  pivot_longer(data = .,
               names_to = 'Variable',
               values_to = 'Valor',
               cols = everything()) %>%

```



```

separate(data = .,
          col = Variable,
          into = c('Variable', 'Regla'),
          sep = '_regla') # Para evitar error con el primer '_'
outliers

```

```


## # A tibble: 18 x 3
##   Variable      Regla  Valor
##   <chr>         <chr>  <int>
## 1 fixed_acidity hampel    34
## 2 fixed_acidity boxplot   20
## 3 volatile_acidity hampel    12
## 4 volatile_acidity boxplot   23
## 5 citric_acid hampel     1
## 6 citric_acid boxplot     1
## 7 residual_sugar hampel   147
## 8 residual_sugar boxplot  138
## 9 density hampel    34
## 10 density boxplot   34
## 11 pH hampel    11
## 12 pH boxplot   19
## 13 sulphates hampel    51
## 14 sulphates boxplot   51
## 15 alcohol hampel    11
## 16 alcohol boxplot     7
## 17 sulfur_dioxide_ratio hampel     0
## 18 sulfur_dioxide_ratio boxplot     5

```

```

# Visualizacion
outliers %>%
  ggplot(data = ., mapping = aes(x = Variable, y = Valor, fill = Regla)) +
  geom_bar(stat = 'identity',
           position = position_dodge()) +
  labs(title = 'Outliers detectados',
       x = 'Variables',
       y = 'Cantidad',
       fill = 'Regla') +
  scale_fill_manual(values = c("hampel" = "steelblue", "boxplot" = "salmon")) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))


```




- c. Representa, mediante un gráfico adecuado, la dispersión del nivel de alcohol según la variable quality, que además muestre los outliers determinados con la regla del boxplot. ¿ qué grado de calidad presenta mayor número de outliers ?

```
# Detectamos outliers para alcohol con regla boxplot
out_alcohol <- datos_proc %>%
  select(quality, alcohol) %>%
  mutate(across(.col = alcohol,
                .fn = list(reglaboxplot = reglaboxplot),
                .names = '{.fn}'))

out_alcohol %>%
  ggplot(data = ., mapping = aes(x = quality, y = alcohol, color = reglaboxplot)) +
  geom_point() +
  geom_jitter()
```



```
out_alcohol %>%  
  ggplot(data = ., mapping = aes(x = quality, y = alcohol, color = reglaboxplot)) +  
  geom_point()
```




Matriz

Obtén la matriz de correlaciones de Pearson entre todas las variables numéricas en `datos_proc`. ¿Cuáles son las variables con mayor correlación? Realiza una representación gráfica de scatter entre las variables numéricas del conjunto.

```
# matrix <- cor(select(datos_proc, where(is.numeric)), use = "complete.obs")
matrix <- datos_proc %>%
  select(where(is.numeric)) %>%
  cor(use = 'complete.obs')

corrplot(corr = matrix, method = "color", type = "upper", tl.cex = 0.7, tl.col = "black")
```




Representaciones graficas

Representaciones gráficas. Partiendo del data frame `datos_proc` realiza las siguientes tareas:


- Representa superpuestos los histogramas de densidad de la variable `alcohol` para cada valor de `quality`. Aplica un `alpha` de 0.5 al histograma. Añade una línea de densidad con un color distinto para cada histograma.

```
datos_proc %>%
  ggplot(data = ., mapping = aes(x = alcohol, fill = quality)) +
  geom_density(alpha = 0.5) +
  labs(title = 'Densidad por quality',
       x = 'Alcohol',
       y = 'Densidad') +
  theme_minimal()
```



- b. Representa un diagrama de dispersión entre `citric_acid` y `fixed_acidity`, incluyendo jitter. Usa un color de punto distinto para cada valor de `quality` y un tamaño de punto proporcional a `residual_sugar`. Ajusta un modelo (método por defecto) para cada valor de `quality` sin representar la desviación estándar.

```
datos_proc %>%
  ggplot(data = .,
    mapping = aes(x = fixed_acidity,
      y = citric_acid,
      color = quality,
      size = residual_sugar)) +
  geom_jitter(alpha = 0.5) +
  labs(title = 'Diagrama de dispersion',
    x = 'Fixed Acidity',
    y = 'Citric Acid') +
  theme_minimal()
```



- c. Representa un diagrama de cajas de pH en función de quality. ¿Cómo se relaciona la calidad del licor con su pH? Añade un gráfico de dispersión para cada caja, incluyendo jitter, coloreando los puntos según citric_acid y su tamaño proporcional a density, con un alpha de 0.1.

```
datos_proc %>%
  ggplot(data = .,
    mapping = aes(x = quality,
      y = pH,
      color = citric_acid,
      size = density)) +
  geom_boxplot(outlier.alpha = 0.3) +
  geom_jitter(alpha = 0.1) +
  labs(title = 'pH por Quality',
    x = 'Quality',
    y = 'pH') +
  theme_minimal()
```

