

Práctica 7. Resumen

Tratamiento de Datos, Grado en Ciencia de Datos - UV

Nombre y Apellidos: _____

Contents

1. Crea un proyecto llamado **Practica7TD** con una carpeta llamada **data** que contenga los ficheros de datos. Las soluciones al ejercicio propuesto se incluirán en un fichero llamado **Practica7TD.Rmd** en el directorio raíz del proyecto.
2. Carga de datos.
 - a. Carga en un data frame el contenido del fichero de datos **licores.csv**. Verifica que las columnas tienen el tipo de dato adecuado a su contenido. Muestra las primeras 10 filas.
 - b. Indica el número de filas, tipo de datos de cada columna y sus estadísticos básicos. ¿Hay valores especiales (**NaN**, **NA**, **Inf**, **-Inf**) en alguna columna?
 - c. Sustituye en los nombres de las variables el carácter espacio ' ' por el carácter barra baja '_ '.
3. Preparación de datos.
 - a. ¿Qué valores distintos contiene la variable **quality**? Conviértela a factor y asigna el valor de sus niveles a 'Muy malo', 'Malo', 'Regular', 'Aprobado', 'Bueno' y 'Muy bueno', por orden de menor a mayor valoración. ¿Cuántas muestras (filas) corresponden a cada nivel?
 - b. Realiza las siguientes operaciones:
 - Crea otra columna llamada **sulfur_dioxide_ratio** que contenga el resultado del cociente entra las columnas **free_sulfur_dioxide** y **total_sulfur_dioxide**.
 - Elimina las dos columnas que has usado para el cálculo. Elimina también la columna **chlorides**.
 - Elimina las filas con un **citric acid** < 0.05 .
 - Ordena las filas de mayor a menor valor de **alcohol**.
 - Redondea todas las variables numéricas a un máximo de 3 decimales.

Enlaza **TODAS** las operaciones con tuberías y guarda el data frame resultante en la variable **datos_proc**.

A partir de ahora debes usar el dataframe **datos_proc** que has obtenido. **NOTA:** Si no has resuelto el anterior ejercicio, usa el data frame que se proporciona en el fichero **datos_proc.Rdata** incluido en la carpeta **data**, para responder a las siguientes preguntas:

4. Determina, para cada valor de **quality**, la media, mediana, desviación estándar y rango intercuartílico de los valores de **alcohol**, redondeando a 2 decimales. Confecciona una tabla como la siguiente. Fíjate que se debe combinar $\text{media} \pm \text{sd}$ en la misma columna. ¿Observas alguna relación entre el nivel de alcohol y la calidad del licor?
5. Datos anómalos.

- a. Determina si hay algún dato anómalo en las variables numéricas usando las reglas **Hampel y Boxplot**. Para cada variable añadirás 2 columnas adicionales. Una al aplicar la regla de Hampel y otra al aplicar la regla del Boxplot que indicará si dicho valor es un outlier (TRUE) o no (FALSE). Suma el número de casos para cada combinación de regla y variable y guarda los resultados como una fila en un data frame **outliers**.
 - b. Representa mediante un diagrama de barras la cantidad de outliers detectada para cada variable y en diferente color para cada regla. Coloca las barras unas al lado de las otras.
 - c. Representa, mediante un gráfico adecuado, la dispersión del nivel de alcohol según la variable **quality**, que además muestre los outliers determinados con la regla del boxplot. ¿qué grado de calidad presenta mayor número de outliers ?
6. Obtén la matriz de correlaciones de Pearson entre todas las variables numéricas en **datos_proc**. ¿Cuáles son las variables con mayor correlación? Realiza una representación gráfica de **scatter** entre las variables numéricas del conjunto.
7. Representaciones gráficas. Partiendo del data frame **datos_proc** realiza las siguientes tareas:
 - a. Representa superpuestos los histogramas de densidad de la variable **alcohol** para cada valor de **quality**. Aplica un alpha de 0.5 al histograma. Añade una línea de densidad con un color distinto para cada histograma.
 - b. Representa un diagrama de dispersión entre **citric_acid** y **fixed_acidity**, incluyendo **jitter**. Usa un color de punto distinto para cada valor de **quality** y un tamaño de punto proporcional a **residual_sugar**. Ajusta un modelo (método por defecto) para cada valor de **quality** sin representar la desviación estándar.
 - c. Representa un diagrama de cajas de **pH** en función de **quality**. ¿Cómo se relaciona la calidad del licor con su pH? Añade un gráfico de dispersión para cada caja, incluyendo **jitter**, coloreando los puntos según **citric_acid** y su tamaño proporcional a **density**, con un alpha de 0.1.